DAFTAR ISI

1 METODE PENELITIAN **2**
1.1 Tempat dan Waktu Penelitian 2
1.2 Alat dan Bahan Penelitian 2
1.2.1 Instrumen Eksperimental dan Preparasi Sampel 2
1.2.2 Perangkat Keras Komputasi 2
1.2.3 Perangkat Lunak 3
1.2.4 Sumber Data Spektroskopik 4
1.3 Prosedur Penelitian 4
1.3.1 Tahap 1: Pembangkitan Data Sintetis 4
1.3.2 Tahap 2: Akuisisi Data Eksperimental 8
1.3.3 Tahap 3: Pemodelan *Deep Learning* 10
1.3.4 Tahap 4: Analisa Sampel dan Pengolahan Data 13
1.4 Hasil yang Diharapkan 14
1.5 Indikator Capaian yang Ditargetkan 15
1.6 Pembagian Kerja Tim Peneliti dan Keterlibatan Mahasiswa 15

1 METODE PENELITIAN

1.1 Tempat dan Waktu Penelitian

Penelitian ini dilaksanakan dalam dua tahap utama yang mencakup kegiatan eksperimental dan komputasional. Tahap eksperimental meliputi preparasi sampel yang dilakukan di **Laboratorium Material, FMIPA Universitas Syiah Kuala**, serta akuisisi data spektrum LIBS yang dilaksanakan di **Laboratorium Optika dan Aplikasi Laser, FMIPA Universitas Syiah Kuala**. Laboratorium ini dilengkapi dengan sistem LIBS berbasis laser Nd:YAG dan spektrometer Echelle yang telah digunakan dalam berbagai studi spektroskopi sebelumnya [1, 2, 3]. Pengukuran komposisi unsur sebagai data referensi (*ground-truth*) menggunakan instrumen X-Ray Fluorescence (XRF) dilakukan di fasilitas analisis yang tersedia di lingkungan Universitas Syiah Kuala.

Tahap komputasional—yang mencakup pembangkitan data sintetis, pengembangan arsitektur model CNN–Transformer encoder–decoder, serta seluruh siklus pelatihan dan evaluasi—dilaksanakan menggunakan **GPU Compute Server** yang tersedia di laboratorium penelitian. Keseluruhan penelitian direncanakan berlangsung selama **10 bulan**, dari Februari 2025 hingga November 2025, dengan rincian per fase disajikan pada bagian Jadwal Penelitian.

1.2 Alat dan Bahan Penelitian

Penelitian ini memadukan pendekatan fisika eksperimental optik dan komputasi *machine learning*. Oleh karena itu, instrumen yang digunakan dikategorikan menjadi instrumen perangkat keras eksperimental, infrastruktur komputasi, perangkat lunak penunjang, serta sumber data.

1.2.1 Instrumen Eksperimental dan Preparasi Sampel

Peralatan eksperimen utama yang digunakan untuk pengadaan sampel tanah vulkanik dan penembakan spektral LIBS disajikan pada Tabel 1.

1.2.2 Perangkat Keras Komputasi

Untuk mengakomodasi kalkulasi dari pembuatan arsitektur *deep learning* (CNN–Transformer) dan *forward modeling* data sintetis, penelitian ini memerlukan kapabilitas komputasi berkinerja tinggi yang disokong oleh:

1. **Laptop Apple MacBook Air M1 2020**: Dilengkapi dengan prosesor *Apple M1*, memori (RAM) sebesar 8 GB, dan penyimpanan *SSD*. Perangkat ini secara utama

Tabel 1: Instrumen Eksperimental Material dan Optik

No	Alat/Bahan	Spesifikasi	Jumlah
1	Laser Nd:YAG	Q-switched, λ = 1064 nm, 114 mJ	1 unit
2	Lensa bikonveks	f = 155 mm (pemfokusan laser)	1 unit
3	Spektrometer Echelle + OMA	Rentang spektral 200–900 nm	1 unit
4	Mesin *hydraulic press*	Tekanan hingga 7 ton	1 unit
5	Mortar, Pestel, dan Ayakan	Penggerusan dan ayakan 40 mesh (420 μm)	1 set
6	Instrumen XRF	*Ground-truth* kuantifikasi elemen	1 unit
7	Sampel tanah vulkanik	G. Seulawah Agam (4 arah $\times$ 3 kedalaman)	24 sampel

digunakan untuk pengembangan skrip kode lokal, eksplorasi matematis awal, dan penyusunan laporan akademis.

2. **Infrastruktur *High Performance Computing* (HPC) Mahameru 4 BRIN**: Infrastruktur ini digunakan secara masif untuk simulasi spektroskopi emisi sintetis berskala besar dan pelatihan model CNN–Transformer yang intensif secara komputasi. Spesifikasi komputasinya meliputi:

   - **Klaster CPU**: 92 *compute node* dengan dual prosesor Xeon Gold (sekitar 32 core per *node*) dan 256 GB RAM per *node*. Terdapat 1 *high memory node* dengan kapasitas memori hingga 1.5 TB.
   - **Klaster GPU**: Terkonsolidasi dari berbagai akselerator *Graphics Processing Unit* kelas berat (di antaranya varian NVIDIA DGX A100, V100, dan P100).
   - **Sistem Penyimpanan**: Kapasitas masif total 4.5 PB, didukung arsitektur *High Performance SSD* untuk menampung matriks HDF5 berjuta-baris dengan efisien.
   - **Jaringan Interkoneksi**: *InfiniBand HDR* (dengan laju transfer 100 Gbps antar sistem server).
   - **Sistem Penjadwalan *Job***: Dikelola melalui antrian basis SLURM (*Simple Linux Utility for Resource Management*).

1.2.3 Perangkat Lunak

Siklus komputasional dan eksekusi jaringan model difasilitasi melalui perangkat lunak berikut:

1. **Sistem Operasi & Lingkungan**: *macOS Ventura 13.6* pada perangkat lokal, dan mesin berbasis *Ubuntu* Linux pada arsitektur server *High Performance Computing*.

2. **Bahasa Pemrograman**: *Python 3.10* ditetapkan sebagai ekosistem operasional primer yang disokong oleh antarmuka *Jupyter Notebook* interaktif untuk validasi prototipe.

3. **Pustaka Algoritma *Deep Learning***: ***PyTorch*** dipilih secara esensial sebagai kerangka kerja tulang punggung arsitektur neural (sub-rutin *Convolution* dan *Cross-Attention*). Digabungkan spesifik dengan modul ***TensorBoard*** untuk pemantauan kurva iteratif metrik regresi per-*epoch* [**?**].

4. **Pustaka Sains Data (*Data Science*)**: *NumPy* dan *Pandas* dimanfaatkan khusus merekayasa kompilasi baris numerik dimensi tinggi; modul *h5py* murni sebagai pengelola *file* ekspor set data spektral HDF5; *scikit-learn* mengeksekusi rotasi grup *5-fold cross validation* & skor akurasi; serta *Matplotlib*/*Seaborn* yang memperindah render komparasi *ground-truth* versus grafik regresi. Modul standar bawaan *itertools* juga digunakan secara masif di belakang layar untuk menjembatani manipulasi agregasi komputasi yang iteratif.

1.2.4 Sumber Data Spektroskopik

NIST Atomic Spectra Database (ASD): Merupakan basis kompilasi standar yang diakses langsung pada server *National Institute of Standards and Technology* [7]. Ekstraksi dari tabel spektra ini menyupli pondasi variabel kuantum seperti batas energi ionisasi ($E_{\infty,i}$), eksitasi energi status (E_k, E_i), degenerasi probabilitas (g_k, g_i), hingga peluruhan transisi foton (A_{ki}) yang menentukan keberhasilan dari algoritma fisika plasma termodinamika buatan kita.

1.3 Prosedur Penelitian

Prosedur pelaksanaan penelitian ini terdiri dari 4 (empat) tahapan utama sebagaimana diilustrasikan dalam diagram alir pada Gambar 1. Penelitian mengikuti alur kerja yang mengintegrasikan pendekatan berbasis simulasi fisika plasma dengan teknik *deep learning*, di mana keterbatasan jumlah data eksperimental (24 sampel) diatasi dengan memanfaatkan pengetahuan fisika plasma melalui data sintetis [5, 6] sebelum mentransfer representasi yang telah dipelajari ke domain eksperimental.

1.3.1 Tahap 1: Pembangkitan Data Sintetis

Keterbatasan utama dalam pengembangan model *deep learning* untuk analisis LIBS adalah minimnya ketersediaan data eksperimental berlabel yang memadai untuk pelatihan.

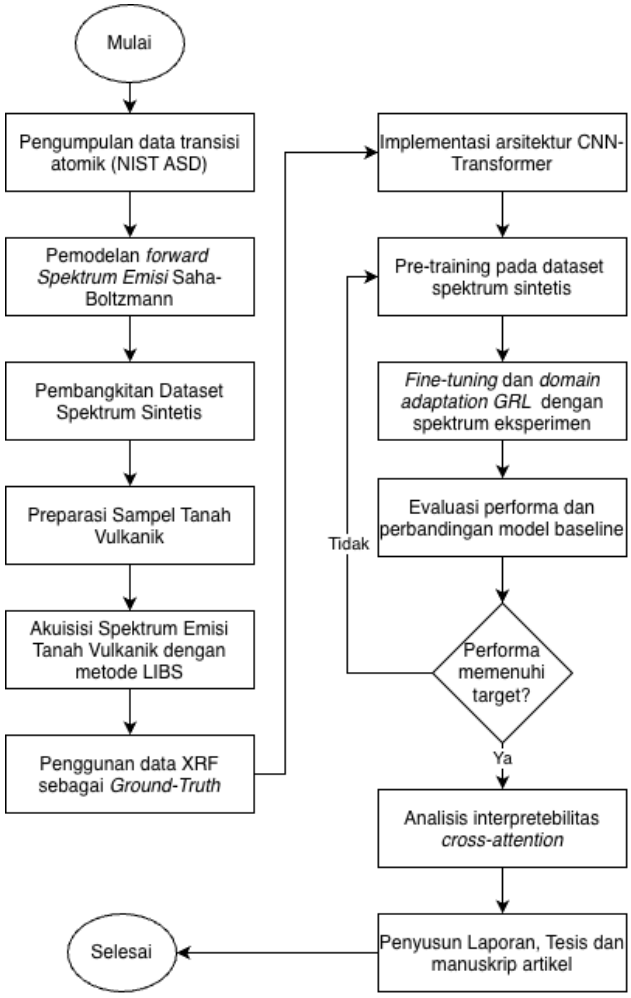

Gambar 1: Diagram alir penelitian.

Untuk mengatasi hal ini, penelitian ini memanfaatkan *forward model* berbasis fisika plasma untuk membangkitkan dataset sintetis berskala besar. Pendekatan ini telah terbukti efektif dalam meningkatkan kemampuan generalisasi model melalui *pre-training* pada data sintetis sebelum *fine-tuning* pada data eksperimental [5, 6]. Tahapan pembangkitan data sintetis adalah sebagai berikut:

1. **Pengumpulan data transisi atomik** dari NIST Atomic Spectra Database [7]: panjang gelombang transisi (λ_{ki}), koefisien Einstein (A_{ki}), degenerasi (g_i), dan energi level (E_i). Agar rentang simulasi bersifat representatif, parameter elemen dikompilasi secara spesifik untuk **8 elemen mayor** dan **15 elemen jejak (*trace elements*)** khas tanah vulkanik, dengan batasan rentang konsentrasi sesuai Tabel 2.

Tabel 2: Rentang referensi komposisi elemen untuk tanah vulkanik yang digunakan dalam pembangkitan dataset spektral sintetis. Elemen dikelompokkan menjadi elemen mayor dan elemen jejak berdasarkan profil geokimia khas tanah vulkanik dan observasi eksperimental XRF.

Grup	**Elemen**	**Rentang Komposisi (%)**	**Peran / Catatan**
Elemen Mayor (*Major Elements* — Komponen matriks utama)			
Mayor	Si	40 – 60	Komponen silikat dominan
Mayor	Al	10 – 18	Mineral aluminosilikat / feldspar
Mayor	Fe	5 – 15	Oksida besi dan mineral feromagnesia
Mayor	Ca	3 – 10	Plagioklas dan mineral karbonat
Mayor	Mg	2 – 8	Mineral olivin dan piroksen
Mayor	Na	1 – 5	Komponen feldspar alkali
Mayor	K	1 – 5	Feldspar kalium
Mayor	Ti	0.5 – 2	Mineral oksida (ilmenit / rutil)
Elemen Jejak (*Trace Elements* — Elemen minor dan penyerta)			
Jejak	Mn	0.05 – 0.5	Berasosiasi dengan mineral Fe
Jejak	P	0.05 – 0.5	Mineral apatit
Jejak	Ba	0.01 – 0.3	Elemen jejak asosiasi alkali
Jejak	Sr	0.01 – 0.2	Mensubstitusi Ca dalam feldspar
Jejak	Zn	0.005 – 0.1	Elemen jejak sulfida / oksida
Jejak	Cu	0.001 – 0.05	Logam jejak sulfida
Jejak	Ni	0.001 – 0.05	Asosiasi mineral mafik
Jejak	Cr	0.001 – 0.05	Indikator mineral ultramafik
Jejak	V	0.001 – 0.05	Logam transisi pada mineral mafik
Jejak	Rb	0.001 – 0.05	Elemen alkali dalam feldspar
Jejak	Pb	0.001 – 0.02	Logam jejak berat
Jejak	Co	0.001 – 0.02	Berasosiasi dengan mineral Fe
Jejak	Mo	0.0005 – 0.01	Logam jejak minor
Jejak	Y	0.0005 – 0.01	Berasosiasi dengan *rare earth element* (REE)
Jejak	Zr	0.001 – 0.02	Mineral penyerta zirkon

2. **Penghitungan populasi analit** memanfaatkan fondasi kesetimbangan termodinamika lokal (*Local Thermodynamic Equilibrium* / LTE). Distribusi probabilitas elektron menempati keadaan tereksitasi dihitung berdasarkan Distribusi Boltzmann [8]:

$$n_{k,z} = n_z \frac{g_{k,z}}{U_z(T_e)} \exp\left(-\frac{E_{k,z}}{k_B T_e}\right) \tag{1}$$

di mana $n_{k,z}$ adalah populasi spesies pada tingkat energi k dan status ionisasi z, $g_{k,z}$ adalah degenerasi statistik dari tingkat energi eksitasi $E_{k,z}$, $U_z(T_e)$ merupakan fungsi partisi, dan k_B melambangkan konstanta Boltzmann. Adapun keseimbangan jumlah partikel antar tingkat ionisasi yang berurutan (netral vs ion) diseimbangkan melalui Persamaan Saha:

$$\frac{n_{z+1} n_e}{n_z} = 2 \frac{U_{z+1}(T_e)}{U_z(T_e)} \left(\frac{m_e k_B T_e}{2\pi\hbar^2}\right)^{3/2} \exp\left(-\frac{E_{\infty,z} - \Delta E_{\infty,z}}{k_B T_e}\right) \tag{2}$$

dengan n_e merepresentasikan densitas elektron, m_e massa elektron, $E_{\infty,z}$ energi ionisasi, dan $\Delta E_{\infty,z}$ koreksi penurunan batas ionisasi akibat rapatnya interaksi plasma. Parameter plasma dominan pada persamaan di atas selanjutnya di-sampling secara acak seragam untuk menghasilkan variasi dataset: $T_e \in [6.000\text{–}15.000]$ K, $n_e \in [10^{16}\text{–}10^{17}]$ cm^{-3}. Rentang ini dipilih berdasarkan kondisi tipikal fluktuasi plasma LIBS pada tekanan atmosfer [9].

3. **Pembangkitan spektrum monoatomik** $S^{(z)}_{\text{mono}}(\lambda)$ per elemen dengan menjumlahkan koefisien emisi spektral menggunakan profil Voigt—konvolusi pelebaran Doppler dan Stark broadening [10]. Profil Voigt dipilih karena merepresentasikan mekanisme pelebaran garis spektral dominan pada plasma LIBS, yaitu pelebaran termal (Doppler) dan pelebaran akibat interaksi elektron (Stark).

4. **Konstruksi spektrum poliatomik**:

$$S_{\text{poly}}(\lambda) = \sum_z c_z \cdot S^{(z)}_{\text{mono}}(\lambda) \tag{3}$$

yaitu superposisi terbobot konsentrasi fraksional. Tahap ini secara eksplisit mengimplementasikan hipotesis dekomposisi mono–poliatomik yang menjadi dasar arsitektur encoder–decoder.

5. **Konvolusi instrumental** dengan fungsi Gaussian (FWHM = 0,02 nm) untuk mencocokkan resolusi spektrometer Echelle yang digunakan dalam eksperi-

men.

6. Total dataset yang dibangkitkan: **10.000 pasangan spektrum sintetis** (monoatomik + poliatomik beserta label konsentrasi dan parameter plasma), dibagi menjadi 80% untuk *training* dan 20% untuk *test*.

7. Ringkasan seluruh parameter fisis dan komputasional yang dilibatkan dalam simulasi *forward model* spektral sintetis ini dirangkum pada Tabel 3.

Tabel 3: Parameter fisis dan instrumental dalam algoritma pembangkitan data spektrum LIBS sintetis.

Kategori / Parameter	**Nilai / Rentang**	**Keterangan**
Rentang Suhu Elektron (T_e)	$6.000 - 15.000$ K	Memodelkan fluktuasi pendinginan plasma [9]
Rentang Densitas Elektron (n_e)	$10^{16} - 10^{17}$ cm^{-3}	Menjamin terpenuhinya kriteria *McWhirter* untuk LTE
Rentang Spektral (λ)	$200 - 900$ nm	Penyesuaian batas rentang deteksi *Echelle spectrometer*
Resolusi Instrumental (FWHM)	0,02 nm	Mereplika batasan resolusi optik nyata dari sistem eksperimen
Profil Bentuk Garis Emisi	Kurva Voigt	Transisi termal gabungan pelebaran *Doppler* dan *Stark*
Fungsi Pelebaran Spektrograf	Distribusi Gaussian	Mendistribusikan piksel menyesuaikan difraksi *grating* alat
Total Spektrum Sintetis	10.000 pasangan set	Varians komprehensif matriks untuk proses *Deep Learning*

1.3.2 Tahap 2: Akuisisi Data Eksperimental

Sampel Penelitian. Penelitian ini memanfaatkan **24 sampel tanah vulkanik** yang telah dikumpulkan dan dipreparasi dalam rangka program riset kolaboratif grup Laboratorium Optika dan Aplikasi Laser, FMIPA USK. Sampel berasal dari lereng **Gunung Seulawah Agam, Kabupaten Aceh Besar, Provinsi Aceh**, yang diambil pada **4 arah mata angin** (Utara, Barat, Selatan, Timur) dan **3 kedalaman** (0–20 cm, 20–40 cm, 40–60 cm) di setiap titik, sehingga merepresentasikan variasi spasial komposisi geokimia secara sistematis. Strategi pengambilan sampel ini konsisten dengan pendekatan yang digunakan oleh Khumaeni et al. [3] pada studi tanah vulkanik Merapi.

Sampel telah dipreparasi menjadi bentuk pelet pada studi sebelumnya melalui prosedur standar:

- Pengeringan pada suhu ruang untuk menghilangkan kelembaban berlebih.

- Penggerusan hingga halus menggunakan mortar dan pestel.
- Penyaringan menggunakan ayakan 40 mesh (420 μm) untuk menyeragamkan ukuran partikel.
- Penimbangan sebanyak kurang lebih 3 gram bubuk per sampel.
- Pengepresan menggunakan mesin *hydraulic press* dengan tekanan 7 ton selama 5 menit hingga terbentuk pelet dengan ketebalan sekitar 4 mm.

Ketersediaan sampel pelet yang telah terpreparasi memungkinkan penelitian ini untuk langsung berfokus pada tahap akuisisi spektrum LIBS baru dan pengembangan model *deep learning*.

Akuisisi Data Spektrum LIBS Baru. Meskipun estimasi komposisi (Tabel 2) dan data baseline awal bersumber dari observasi XRF dan CF-LIBS studi terdahulu, standar kualitas data spektral eksperimental masa lalu belum optimal untuk skenario pelatihan komputasi modern. Oleh karena itu, akuisisi spektrum LIBS **dilakukan secara baru dan independen** terhadap 24 sampel pelet tersebut. Fokus pembaruan eksperimen terletak pada peningkatan agregasi pengukuran: **jumlah tembakan laser (*shots*)** akan diperbanyak secara masif. Penambahan akumulasi tembakan ini sangat esensial untuk mengatasi fluktuasi ketidakstabilan plasma dan menekan profil *noise* temporal. Hasilnya, *Signal-to-Noise Ratio* (SNR) akan meningkat drastis, sehingga jaringan *deep learning* kelak dapat mendeteksi intensitas emisi lemah secara akurat tanpa tertukar dengan *noise*.

Pengukuran dilaksanakan menggunakan sistem LIBS di Laboratorium Optika dan Aplikasi Laser, FMIPA USK. Prosedur pengambilan datanya adalah sebagai berikut:

- Berkas laser Nd:YAG (λ = 1064 nm, energi pulsa 114 mJ) difokuskan pada permukaan sampel pelet menggunakan lensa bikonveks (f = 155 mm) untuk membangkitkan plasma.
- Serat optik dihubungkan ke sistem spektrograf dan diarahkan ke bilik sampel untuk menangkap emisi plasma.
- Sampel pelet diposisikan di dalam bilik sampel dan jarak fokus disesuaikan untuk memperoleh intensitas plasma yang ideal.
- Emisi plasma tertangkap akan direkam menggunakan *Optical Multichannel Analyzer* (OMA) berbasis spektrometer Echelle (rentang 200–900 nm).
- Setiap sampel diablasi dengan **kuantitas tembakan (*multiple shots*) tinggi** pada *crater* / permukaan titik yang berbeda, lalu semua tangkapan spektral

dirata-ratakan secara presisi guna memperoleh stabilitas *continuum background* dan ketajaman puncak.

- Data spektrum yang terekam ditampilkan dan disimpan menggunakan komputer untuk analisis lebih lanjut.
- Garis-garis emisi diidentifikasi menggunakan database NIST Atomic Spectra Database [7].

Data Ground-Truth Konsentrasi (XRF). Data konsentrasi elemen untuk seluruh 24 sampel telah tersedia dari pengukuran **X-Ray Fluorescence (XRF)** yang dilakukan pada studi sebelumnya dalam program riset grup. Data XRF ini digunakan dalam penelitian ini sebagai *ground-truth* konsentrasi unsur untuk supervisi pada tahap *fine-tuning* model. Penggunaan data XRF yang sudah ada memastikan konsistensi referensi antara studi terdahulu dan penelitian ini, serta menghindari pengulangan pengukuran yang tidak diperlukan. XRF dipilih sebagai referensi karena kemampuannya memberikan analisis kuantitatif multi-elemen yang akurat secara non-destruktif.

1.3.3 Tahap 3: Pemodelan *Deep Learning*

Arsitektur Model CNN–Transformer Encoder–Decoder. Arsitektur model yang diusulkan dalam penelitian ini dirancang berdasarkan prinsip dekomposisi spektral mono–poliatomik eksplisit, di mana spektrum campuran poliatomik dimodelkan sebagai superposisi terbobot dari spektrum monoatomik penyusunnya. Secara teknis, rancangan jaringan ini ditunjukkan secara menyeluruh pada Gambar 2. Arsitektur encoder–decoder dipilih karena secara natural mampu memodelkan hubungan antara komponen individu (monoatomik via encoder) dan campurannya (poliatomik via decoder) melalui mekanisme *cross-attention* [11, 12].

Komponen utamanya adalah sebagai berikut:

1. **1D-CNN Feature Extractor** (*shared* encoder–decoder): Dieksekusi secara berulang sebanyak 3 kali blok tumpukan (terdiri dari Conv1D $\rightarrow$ Batch Normalization $\rightarrow$ GELU $\rightarrow$ Max Pooling 1D). Blok ini secara krusial menangkap fitur lokal profil emisi/bentuk garis dan mereduksi resolusi spasial sekuens panjang gelombang.
2. **Transformer Encoder** (4 layer, 8 attention heads): menerima fitur CNN dari **seluruh** spektrum monoatomik (*concatenated*) + *positional* & *element-type embedding* $\rightarrow$ menghasilkan representasi laten spesifik-elemen via *self-*

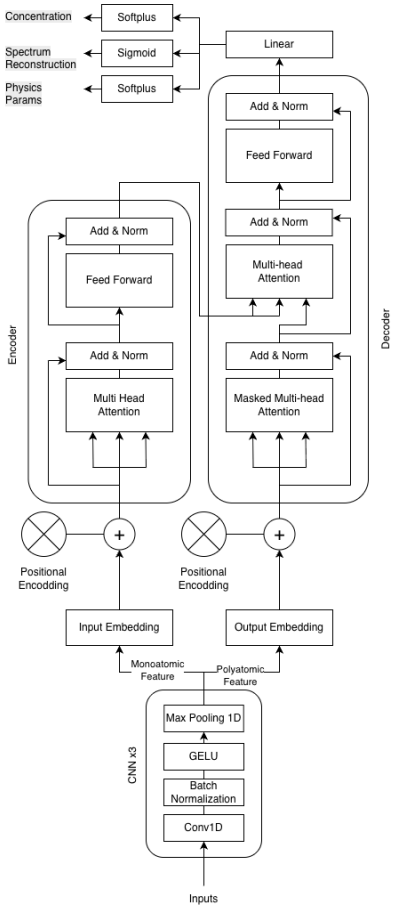

Gambar 2: Representasi visual Arsitektur CNN–Transformer Encoder–Decoder untuk analisis spektral LIBS. Blok ekstrasi fitur 1D CNN dimanfaatkan untuk mereduksi sekuens panjang gelombang sebelum memasuki lapisan atensi Transformer.

attention. Encoder mempelajari bagaimana setiap elemen berkontribusi terhadap sinyal spektral secara individual.

3. **Transformer Decoder** (4 layer, 8 heads): menerima fitur CNN spektrum campuran poliatomik → ***masked self-attention*** → ***cross-attention*** terhadap output encoder → mempelajari aturan komposisi spektral. Mekanisme *cross-attention* memungkinkan decoder untuk meng-query representasi elemen dari encoder dan menentukan kontribusi masing-masing elemen terhadap spektrum campuran yang diamati.

4. **Regression Head**: Global Average Pooling → Linear projection → vektor konsentrasi $\hat{\mathbf{c}} \in \mathbb{R}^Z$.

5. **Tiga output head**: (i) konsentrasi elemen (aktivasi Softplus), (ii) rekonstruksi spektrum (Sigmoid), (iii) parameter plasma T_e, n_e (Softplus). Desain *multi-task* ini mendorong model untuk tidak hanya memprediksi konsentrasi, tetapi juga mempertahankan konsistensi dengan fisika plasma yang mendasarinya.

Strategi Pelatihan. Strategi pelatihan model dirancang dalam tiga fase berurutan untuk memaksimalkan transfer pengetahuan dari domain sintetis ke domain eksperimental. Skema komplit dari alur adaptasi domain ini dapat dilihat pada Gambar 3.

1. **Pre-training** pada data sintetis: 200 epoch, learning rate 10^{-4}, optimizer Adam [15] dengan *cosine annealing schedule* [16]. Fungsi loss gabungan digunakan:

$$\mathcal{L} = \mathrm{MSE}_{\text{konsentrasi}} + \alpha \times \mathrm{MSE}_{\text{rekonstruksi spektral}} \quad (\alpha = 0{,}1) \tag{4}$$

   Komponen rekonstruksi spektral berfungsi sebagai regularisasi fisika, memastikan model memetakan fitur spektral yang bermakna secara fisik.

2. **Fine-tuning** pada data eksperimental LIBS: 50 epoch, learning rate 10^{-5} (lebih rendah untuk mencegah *catastrophic forgetting*), dengan target *ground-truth* konsentrasi dari pengukuran XRF.

3. **Domain adaptation**: Gradient Reversal Layer (GRL) [17] + domain classifier (sintetis vs eksperimental) diintegrasikan selama pelatihan untuk mendorong encoder menghasilkan representasi yang *domain-invariant*. Pendekatan ini mengatasi *domain gap* antara spektrum sintetis (yang mengasumsikan LTE ideal) dan spektrum eksperimental (yang mengandung noise, fluktuasi tembakan-ke-tembakan, dan deviasi dari LTE).

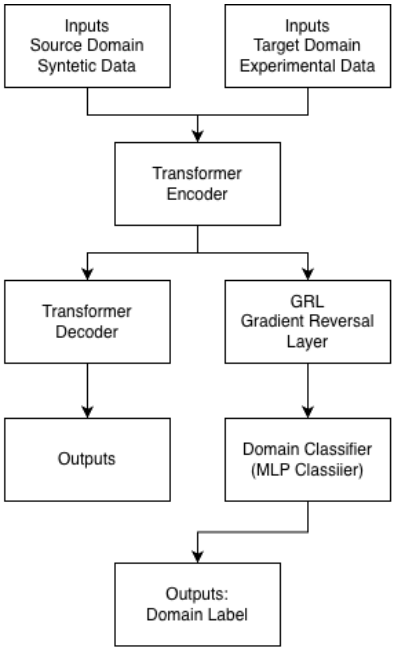

Gambar 3: Skema *Domain Adaptation* menggunakan *Gradient Reversal Layer* (GRL). Arsitektur ini memaksa *Transformer Encoder* untuk menghasilkan representasi fitur laten yang tidak bisa dibedakan oleh *Domain Classifier*, sehingga menjembatani *domain gap* antara spektrum sintetis dan eksperimental.

1.3.4 Tahap 4: Analisa Sampel dan Pengolahan Data

Hasil akuisisi eksperimental dianalisis lebih lanjut melalui serangkaian tahapan komputasional. Pemrosesan data mentah dan analisis luaran model mencakup:

- **Pra-pemrosesan spektrum**: normalisasi intensitas terhadap kurva respons sistem (*instrumental response*), koreksi kontinum *baseline* melalui algoritma polynomial fitting, dan segmentasi rentang panjang gelombang fokus untuk membuang *background noise*.
- **Identifikasi garis emisi**: pencocokan otomatis antar puncak profil spektrum yang terukur dengan *database* referensi NIST ASD guna memvalidasi keberadaan matriks elemen target.
- **Inferensi model**: spektrum eksperimental yang telah bersih diumpankan ke model prediksi *deep learning* (CNN–Transformer) yang telah terbiasa dengan spektrum sintetis untuk mengekstrak vektor konsentrasi elemen (*end-to-end mapping*).
- **Analisis komparatif**: penyelarasan keluaran prediksi konsentrasi dari pemodelan AI terhadap perolehan data eksak XRF sebagai landasan validasi metrik (*ground-truth*).

Protokol Evaluasi Metrik

Evaluasi kapabilitas analitik model dihimpun secara komprehensif menggunakan protokol:

- **3 metrik kuantitatif per elemen**: *Root Mean Square Error* (RMSE) untuk melacak rata-rata deviasi kuadratik, *Koefisien Determinasi* (R^2) memonitor proporsi korelasi linier prediksi absolut, dan *Mean Absolute Percentage Error* (MAPE) sebagai parameter akurasi relatif spasial.
- **4 model baseline** sebagai komparasi ketangguhan: PLS—*Partial Least Squares* [18] sebagai representasi perbandingan regresi kemometrik klasik, model spasial diskrit (CNN-only), penyesuai sekuens independen (Transformer-only), dan arsitektur canggih *Informer* [19, 4].
- **Keterandalan Lintas-Validasi**: *stratified 5-fold cross-validation* diimplementasikan pada dataset eksperimental untuk menihilkan anomali uji (mencegah *overfitting*) serta menyajikan jaminan *robustness* validasi di situasi jumlah sampel yang terbatas.
- **Interpretabilitas Fisik**: penelusuran balik bobot koneksi *cross-attention* dari matriks *decoder* ke *encoder*. Pendekatan ini melegitimasi apakah mesin neural secara mandiri menemukan hubungan spasi-waktu transisi kuantum elemen, menegaskan bahwa simulasi benar-benar mempelajari dekomposisi mono–poliatomik sesuai hukum fisika, bukan sekadar intuisi korelasi statistik "kotak hitam" semata.

1.4 Hasil yang Diharapkan

Dari pelaksanaan penelitian ini, diharapkan diperoleh hasil sebagai berikut:

1. **Model CNN–Transformer encoder–decoder** yang terlatih dan mampu melakukan kuantifikasi multi-elemen pada spektrum LIBS tanah vulkanik dengan akurasi yang superior dibandingkan model baseline (PLS, CNN-only, Transformer-only, Informer).
2. **Validasi konsep dekomposisi spektral mono–poliatomik** melalui analisis bobot *cross-attention*, yang menunjukkan bahwa model secara eksplisit mempelajari kontribusi spektral masing-masing elemen dalam spektrum campuran.

3. **Profil konsentrasi 7 elemen mayor** (Si, Al, Fe, Ca, Mg, Na, K) dari 24 sampel tanah vulkanik lereng Gunung Seulawah Agam, Aceh, yang divalidasi terhadap pengukuran XRF.

4. **Metode kuantifikasi LIBS baru** yang mengintegrasikan pengetahuan fisika plasma (*physics-informed*) ke dalam arsitektur *deep learning*, membuka peluang analisis geokimia cepat tanpa kalibrasi standar.

5. **Manuskrip jurnal ilmiah** yang siap disubmit ke jurnal internasional bereputasi.

1.5 Indikator Capaian yang Ditargetkan

- Minimal **satu publikasi ilmiah** di jurnal internasional bereputasi. Jurnal yang ditargetkan: **IOP Machine Learning: Science and Technology** (Q1, terindeks Scopus). Sebagai alternatif: *Spectrochimica Acta Part B* atau *Journal of Analytical Atomic Spectrometry*.

- **Penyelesaian tesis** mahasiswa magister dalam rentang waktu yang direncanakan (10 bulan).

- **Peningkatan kapasitas laboratorium** dalam pengembangan dan penerapan metode *deep learning* untuk analisis spektroskopi LIBS, yang dapat digunakan untuk penelitian lanjutan di lingkungan Laboratorium Optika dan Aplikasi Laser, FMIPA USK.

1.6 Pembagian Kerja Tim Peneliti dan Keterlibatan Mahasiswa

Pustaka

[1] Mitaphonna, R., Ramli, M., Ismail, N., Hartadi, B.S., & Idris, N. (2023). *J. Phys.: Conf. Ser.*, 2582(1), 012033.

[2] Mitaphonna, R., Ramli, M., Ismail, N., & Idris, N. (2024). *Indonesian Journal of Chemistry*, 24(3).

[3] Khumaeni, A. et al. (2025). *Talanta*, 295, 128376.

[4] Walidain, B. et al. (2026). *IOP Conf. Ser.: Earth Environ. Sci.*, in press.

[5] Wang, Y. et al. (2024). Simulation of laser-induced plasma temperature based on machine learning.

Tabel 4: Pembagian Kerja Tim Peneliti

No	Status	Instansi / Bidang	Uraian Tugas
1	Ketua	FMIPA USK / Optika & Laser Spektroskopi	Mengkoordinasi pelaksanaan penelitian, mensupervisi pengukuran LIBS dan analisis data, serta mereview manuskrip publikasi
2	Anggota	FMIPA USK / [Bidang Ilmu]	Supervisi metode komputasi dan pengembangan model *deep learning*
3	Anggota	FMIPA Fisika USK / Fisika Komputasi & Spektroskopi	Implementasi arsitektur CNN–Transformer, pembangkitan data sintetis, preparasi sampel, pengambilan data eksperimental LIBS, serta penulisan draf tesis dan manuskrip publikasi

[6] Favre, A. et al. (2025). *Spectrochimica Acta Part B*, 224, 107082.

[7] Kramida, A. et al. (2024). NIST Atomic Spectra Database (ver. 5.12).

[8] Fujimoto, T. (2004). *Plasma Spectroscopy*. Oxford: Clarendon Press.

[9] Cristoforetti, G. et al. (2010). *Spectrochimica Acta Part B*, 65(1), 86–95.

[10] Griem, H.R. (1974). *Spectral Line Broadening by Plasmas*. Academic Press.

[11] Vaswani, A. et al. (2017). *Advances in NeurIPS*, 30.

[12] Liu, D. et al. (2026). *AIP Advances*, 16(4), 045110.

[13] He, K. et al. (2016). *Proc. IEEE CVPR*, 770–778.

[14] Ioffe, S. & Szegedy, C. (2015). *Proc. ICML*, 37, 448–456.

[15] Kingma, D.P. & Ba, J. (2015). *Proc. ICLR 2015*.

[16] Loshchilov, I. & Hutter, F. (2017). *Proc. ICLR 2017*.

[17] Ganin, Y. et al. (2016). *JMLR*, 17(59), 1–35.

[18] Wold, S. et al. (2001). *Chemom. Intell. Lab. Syst.*, 58(2), 109–130.

[19] Zhou, H. et al. (2021). *Proc. AAAI*, 35(12), 11106–11115.